

LiteLLM

제공사가 바뀌어도 코드는 그대로 — 100+ LLM을 하나로 연결하는 AI Gateway

Open Source AI Gateway | BerriAI | Y Combinator W23

53,000+ GitHub Stars · 22,900+ 프로덕션 채택

LiteLLM이란?

≡ 통합 인터페이스

OpenAI, Anthropic, Vertex AI 등 100개 이상의 LLM을 하나의 completion() 호출로 사용. provider만 바꾸면 코드 수정 불필요.

☰ AI Gateway

Self-hosted 프록시 서버로 팀 전체의 LLM 접근을 중앙 관리. Virtual Keys, 예산 제한, 로드 밸런싱을 오픈소스로 제공.

<> Python SDK

OpenAI SDK와 100% 호환. completion, embedding, streaming을 동일한 인터페이스로 호출하고, Observability 콜백으로 즉시 모니터링 가능.

🚀 프로덕션 레디

P95 레이턴시 8ms @ 1k RPS. Docker, Terraform, Helm Chart 등 검증된 배포 옵션. Stripe, Google ADK 등 대규모 기업 채택.

53k+

GitHub Stars

100+

Support Providers

22.9k

Used by Projects

1,398

Releases

핵심 기능



Unified Interface

provider/model 형식으로 호출하면 SDK, 인증, 포맷 차이를 완전히 추상화. 코드 변경 없이 모델 전환 가능.



Routing & Failover

여러 배포 간 로드 밸런싱 + 장애 시 자동 fallback. Azure, OpenAI 등 크로스 배포 장애도 자동 복구.



Guardrails

콘텐츠 필터링, PII 마스킹, 안전성 검사를 요청/응답 파이프라인에 삽입. 커스텀 가드레일도 가능.



Cost Tracking

키별, 팀별, 사용자별 사용량과 비용을 실시간 추적. 예산 한도 초과 시 자동 차단 지원.



MCP & Agent Gateway

LLM 호출뿐 아니라 MCP 도구, A2A 에이전트까지 하나의 엔드포인트로 통합. 별도 게이트웨이 불필요.



Observability

Langfuse, MLflow, Helicone 등과 원 줄 콜백으로 즉시 연동. 커스텀 콜백으로 전 과정 모니터링 가능.

지원 LLM 제공사

카테고리	제공사	타입
메이저 클라우드	OpenAI, Anthropic, Google Vertex AI, Azure OpenAI, AWS Bedrock	Cloud
추가 클라우드	Cohere, AI21, PaLM, Sagemaker, IBM watsonx	Cloud
오픈소스 / Self-host	Ollama, vLLM, HuggingFace, NVIDIA NIM, Text Generation Inference	Local
에이전트 프레임워크	LangChain, LlamaIndex, Google ADK, CrewAI	Framework
기타	100개 이상의 추가 제공사 · 새 제공사 지속 추가 중	+More

Quick Start

Python SDK

model 파라미터만 바꾸면 모든 제공사를 동일한 방식으로 호출합니다.

```
from litellm import completion # OpenAI
response = completion( model="openai/gpt-4o",
messages=[{"role": "user", "content": "안녕하세요!"}] ) # 제공사 전환 - 코드 변경 불필요 #
model="anthropic/claude-3-5-sonnet" #
model="vertex_ai/gemini-1.5-pro" #
model="bedrock/anthropic.claude-haiku"
```

Proxy Server (AI Gateway)

프록시를 배포하면 OpenAI SDK를 그대로 사용할 수 있습니다.

```
# 프록시 시작 $ litellm --model openai/gpt-4o #
→ http://localhost:4000 # OpenAI SDK로 그대로 호출
import openai client = openai.OpenAI(
api_key="anything",
base_url="http://localhost:4000" ) response =
client.chat.completions.create( model="gpt-4o", messages=[{"role": "user", "content":
"Write a poem"}] )
```

에러 핸들링 & Observability

에러를 제공사에 맞춰 자동 변환

- 모든 제공사 에러를 OpenAI 예외 타입으로 자동 매핑
- AuthenticationError, RateLimitError 등 일관된 인터페이스
- 제공사를 바꿔도 기존 에러 핸들링 코드 그대로 유지
- Streaming, Function Calling 등 모든 시나리오에서 동작

전 과정을 한 줄로 추적

- Langfuse, MLflow, Helicone 등 성숙한 관측 도구와 즉시 연동
- 커스텀 콜백으로 요청/응답/비용/레이턴시 전부 수집
- OpenTelemetry 기반 분산 추적 지원
- 프로덕션 환경에서도 부담 없는 오버헤드

유연한 배포 방식

Docker

docker run 또는 docker-compose로 즉시 배포. 프로덕션 환경에서도 안정적으로 사용 가능합니다.

가장 간편한 시작

Terraform

AWS ECS Fargate, GCP Cloud Run용 프로덕션 모듈 제공. Managed Postgres + Redis 통합 구성.

인프라 자동화

Kubernetes

Helm Chart로 K8s 클러스터에 배포. Auto-scaling, 서비스 디스커버리, 로드 밸런싱 지원.

대규모 오케스트레이션

Managed Service

BerriAI에서 호스팅하는 완전 관리형 버전. 인프라 걱정 없이 바로 사용, 엔터프라이즈 SLA 적용.

완전 관리형

엔터프라이즈 기능

오픈소스로 충분히 강력한 기반

- 100+ LLM 제공사 통합 지원
- Python SDK & Proxy Server
- Virtual Keys & Budget 관리
- Load Balancing & Failover
- Cost Tracking & Observability
- Docker / Terraform / Helm 배포

엔터프라이즈로 한 단계 더

- SSO / SAML 인증으로 안전한 접근 관리
- 감사 로그 (Audit Logs)로 활동 추적
- 고급 보안 기능 & 데이터 격리
- 전용 지원 채널 (Discord + Slack)
- 커스텀 SLA & 우선 기능 구현
- Stripe, Google 등 대규모 기업 검증

총 정리

100+

지원 LLM

53k+

GitHub Stars

8ms

P95 Latency

22.9k

프로덕션 채택

핵심 장점

Unified 하나의 completion()으로 모든 LLM 호출

Compatible OpenAI SDK 100% 호환 — 코드 변경 불필요

Production Virtual Keys, Budget, Guardrails 내장

Flexible Docker, Terraform, Helm, Managed 중 선택

Extensible MCP, A2A Agent, Observability 통합

LLM 제공사를 바꿀 때마다 코드를 고치는 대신, LiteLLM 하나로 해결하세요.

[GitHub](#)

[Documentation](#)

[Community Discord](#)